

BÁO CÁO TUẦN 4 — Tổng quát hoá đa LLM và Hoàn thiện báo cáo

Thời gian: 23/06 – 30/06/2026 • Trạng thái: Đang triển khai

Trợ lý hỏi đáp thủ tục hành chính công Việt Nam ứng dụng Agentic RAG

Nhóm: Nguyễn Xuân Phúc, Nguyễn Minh Triết

GVHD: Đỗ Trọng Hợp, Nguyễn Ngọc Quý

1 Mục tiêu tuần

Tuần cuối hướng tới việc tách hệ thống khỏi sự phụ thuộc vào một nhà cung cấp mô hình duy nhất: trừu tượng hoá tầng LLM và embedding để chạy được trên Azure OpenAI, OpenAI và các mô hình mã nguồn mở phục vụ qua vLLM. Song song đó, nhóm hoàn thiện bộ tài liệu vận hành và báo cáo (báo cáo chính cùng bốn báo cáo tuần).

2 Công việc đã thực hiện

Trừu tượng hoá tầng mô hình (Model Gateway): Nhóm định nghĩa một cổng mô hình (model gateway) độc lập nhà cung cấp (provider-agnostic): phần lõi RAG chỉ gọi tới mô hình thông qua một interface chung cho hai tác vụ là sinh văn bản dạng chat và nhúng vector, không phụ thuộc vào SDK cụ thể của bất kỳ nhà cung cấp nào. Thông tin nhà cung cấp, tên mô hình và khoá xác thực được khai báo hoàn toàn qua tệp `.env` và trang Settings, cho phép đổi mô hình mà không phải sửa mã nguồn.

Các bộ tương hợp (Adapters): Trên nền interface chung, nhóm bổ sung các bộ tương hợp cho từng nhà cung cấp, tóm tắt ở Bảng 1. Đáng chú ý, các mô hình mã nguồn mở tự host (Llama, Qwen) được phục vụ qua vLLM với một endpoint tương thích OpenAI, nên chỉ cần trỏ tham số `base_url` về máy chủ vLLM là tái dùng được cùng một bộ tương hợp với OpenAI.

Nhà cung cấp	Giao tiếp	Ghi chú
Azure OpenAI	SDK Azure (hiện có)	<code>gpt-4o</code> và <code>text-embedding-3-large</code> (đang dùng).
OpenAI	API OpenAI chuẩn	Đổi khoá và endpoint, tái dùng cùng interface chat/embedding.
Mã nguồn mở qua vLLM	Endpoint tương thích OpenAI	Tự host (Llama, Qwen); chỉ trỏ <code>base_url</code> về máy chủ vLLM.

Table 1: Các bộ tương hợp nhà cung cấp mô hình.




Figure 1: Model Gateway độc lập nhà cung cấp: lỗi RAG không đổi, chỉ chọn nhà cung cấp qua cấu hình.



Figure 2: Chọn mô hình theo nhà cung cấp trong trang cấu hình.

Kiểm thử và lưu ý kỹ thuật: Nhóm kiểm thử đầu cuối cho từng nhà cung cấp, bao gồm sinh chat kèm streaming và gọi công cụ của agent, cũng như tác vụ nhúng và toàn luồng RAG. Một lưu ý quan trọng là khi đổi mô hình nhúng, số chiều vector sẽ thay đổi và bắt buộc phải nhúng lại (reindex) toàn bộ corpus; do đó nhóm tách riêng cấu hình nhúng khỏi cấu hình sinh và cảnh báo rõ khi số chiều thay đổi. Với vLLM, máy chủ cần có GPU, và nhóm chuẩn hoá các khác biệt nhỏ giữa các endpoint tương thích OpenAI như định dạng gọi công cụ hay tham số dừng.



Figure 3: Kiểm thử cùng câu hỏi trên nhiều nhà cung cấp LLM.

Hoàn thiện hệ thống vận hành và báo cáo: Nhóm chuẩn bị các kịch bản khởi chạy (run-backend, run-frontend) có bật sẵn chế độ UTF-8 để tránh lỗi mã hoá tiếng Việt trên console Windows, cùng cơ chế chia sẻ index dựng sẵn qua HuggingFace để tái lập nhanh trên máy mới. Về tài liệu, nhóm biên soạn báo cáo chính (gồm các phần Giới thiệu, Công trình liên quan, Phương pháp và Kế hoạch) cùng bốn báo cáo tuần chi tiết, thống nhất sơ đồ luồng và bảng số liệu giữa các tài liệu.

3 Sản phẩm bàn giao (dự kiến)

Thành phần	Mô tả
Model Gateway	Interface chung cho LLM và embedding, độc lập nhà cung cấp.
Adapters	Azure OpenAI, OpenAI, vLLM (endpoint tương thích OpenAI).
Cấu hình	Chọn nhà cung cấp và mô hình qua <code>.env</code> và <code>Settings</code> , không sửa mã.
Tài liệu vận hành	Hướng dẫn cấu hình và lưu ý reindex khi đổi mô hình nhúng.
Bộ báo cáo PDF	Báo cáo chính và bốn báo cáo tuần.

4 Rủi ro và cách kiểm soát

- Đổi mô hình nhúng kéo theo phải nhúng lại toàn bộ corpus: tách cấu hình nhúng khỏi cấu hình sinh và cảnh báo rõ khi số chiều thay đổi.
- Khác biệt giữa các endpoint của các nhà cung cấp: lớp tương hợp che giấu khác biệt và nhóm kiểm thử hồi quy cho từng nhà cung cấp.
- Chi phí và hạ tầng: mô hình mã nguồn mở giảm phụ thuộc dịch vụ trả phí nhưng cần GPU, nhóm nên khuyến nghị triển khai theo nhu cầu thực tế.

5 Checklist tuần 4

- ☐ Trừu tượng hoá tầng LLM và embedding (Model Gateway độc lập nhà cung cấp).
- ☐ Adapter Azure (có sẵn), OpenAI và vLLM; chọn mô hình qua cấu hình.
- ☐ Kiểm thử đầu cuối từng nhà cung cấp (chat, streaming, embedding).
- ☐ Hoàn thiện báo cáo chính và bốn báo cáo tuần.

6 Kết luận dự án

Sau bốn tuần, đồ án đi trọn một vòng từ khâu dữ liệu (5.208 thủ tục, kho truy hồi ba lớp), qua đường cơ sở một lượt có trích dẫn, tới kiến trúc Agentic RAG (tác tử ReAct hai giai đoạn có minh bạch hoá suy luận và trích dẫn kèm tô sáng), và cuối cùng là tổng quát hoá đa nhà cung cấp LLM. Kết quả là một trợ lý hỏi đáp thủ tục hành chính công có căn cứ, minh bạch và dễ triển khai.