

BÁO CÁO TUẦN 4 — Bộ nhớ hội thoại, Định vị cơ quan (bản đồ) và Đánh giá định lượng

Thời gian: 23/06 – 30/06/2026 • Trạng thái: Đã hoàn thành

Trợ lý hồi đáp thủ tục hành chính công Việt Nam ứng dụng Agentic RAG

Nhóm: Nguyễn Xuân Phúc, Nguyễn Minh Triết

GVHD: Đỗ Trọng Hợp, Nguyễn Ngọc Quý

1 Mục tiêu tuần

Tuần cuối tập trung vào ba mảng để hoàn thiện trải nghiệm và kiểm chứng chất lượng hệ thống: (1) trang bị bộ nhớ hội thoại đa lớp giúp trợ lý hồi đáp đa lượt tự nhiên, giải được các tham chiếu vượt cửa sổ lịch sử; (2) bổ sung tính năng định vị cơ quan xử lý thủ tục gần người dùng kèm bản đồ và chỉ đường; (3) xây dựng bộ dữ liệu đánh giá có nhãn và đo định lượng toàn hệ thống. Song song, nhóm hoàn thiện báo cáo chính và bốn báo cáo tuần.

2 Công việc đã thực hiện

Bộ nhớ hội thoại hai lớp (Conversation Memory): Tác tử ReAct ở pha gom nguồn vốn không dùng lịch sử hội thoại, nên các câu hỏi tiếp nối nằm ngoài cửa sổ lịch sử dễ bị lạc chủ đề. Nhóm bổ sung một bộ nhớ phân tầng (`rag/memory.py`) đóng khung theo mô hình bộ nhớ kiểu hệ điều hành (MemGPT). *Lớp A* — *Summary-Buffer* giữ nguyên văn vài lượt gần nhất và tóm tắt bằng LLM các lượt cũ, qua đó giữ ngữ cảnh dài mà không phình token. *Lớp B* — *Episodic* lưu mỗi lượt hỏi đáp (và tùy chọn các *fact* của người dùng) vào một collection Chroma riêng, khóa theo `user_id`, rồi truy hồi (recall) top-*k* ký ức liên quan trước khi tra cứu. Trước Giai đoạn 1, hệ tóm tắt và recall ký ức rồi tiêm vào bước contextualize để viết lại câu hỏi tiếp nối thành câu hỏi độc lập — ví dụ “Lệ phí của thủ tục này là bao nhiêu?” được giải thành “Lệ phí của thủ tục xin cấp hộ chiếu phổ thông là bao nhiêu?”. Sau mỗi lượt, cặp hỏi đáp được ghi vào ký ức dài hạn. Mọi điểm gọi bộ nhớ đều được bọc `try/except` để lỗi bộ nhớ không bao giờ làm hỏng câu trả lời; từng lớp bật tắt độc lập qua biến môi trường (`MEM_SUMMARY`, `MEM_EPISODIC`, `MEM_FACTS`) phục vụ thí nghiệm cắt bỏ (ablation).

Thủ tục cấp hộ chiếu phổ thông cần những giấy tờ gì?

🔄 Quá trình suy luận ^

🔴 Nhớ lại từ trước: Người dùng từng hỏi: Thủ tục cấp hộ chiếu phổ thông cần những giấy tờ gì? Đáp: Hồ sơ cấp hộ chiếu phổ thông cần các giấy tờ sau: 1. Bản sao giấy khai sinh hoặc trích lục khai sinh đối với người chưa đủ 14 tuổi 【1】. 2. 02 ảnh mới chụp không quá 06 tháng, cỡ 4cm x 6cm, mặt nhìn thẳng, đầu để trần, rõ mặt, rõ hai tai, không đeo kính, trang phục lịch sự, phông nền trắng 【2】. 3. Bản chụp có chứng thực giấy tờ do cơ quan có thẩm quyền của Việt Nam cấp chứng minh người đại diện hợp | Người dùng từng hỏi: Tôi muốn làm hộ chiếu phổ thông ở trong nước. Đáp: Hồ sơ gồm: 1. 01 tờ khai để nghị cấp hộ chiếu phổ thông (mẫu TK01) ban hành kèm theo Thông tư số 73/2021/TT-BCA ngày 29/6/2021 của Bộ Công an 【1】. 2. Bản sao giấy khai sinh hoặc trích lục khai sinh đối với người chưa đủ 14 tuổi 【2】. 3. 02 ảnh mới chụp không quá 06 tháng, cỡ 4cm x 6cm, mặt nhìn thẳng, đầu để trần, rõ mặt, rõ hai tai, không đeo kính, trang phục lịch sự, phông nền trắng 【3】. 4. Bản chụp | Người dùng từng hỏi: Tôi muốn làm hộ chiếu Đáp: Để làm hộ chiếu phổ thông ở trong nước (thực hiện tại cấp trung ương), bạn cần thực hiện các bước sau: 1. **Chuẩn bị hồ sơ**: - 01 tờ khai để nghị cấp hộ chiếu phổ thông (mẫu TK01) ban hành kèm theo Thông tư số 73/2021/TT-BCA ngày 29/6/2021 của Bộ Công an 【1】. - 02 ảnh mới chụp không quá 06 tháng, cỡ 4cm x 6cm, mặt nhìn thẳng, đầu để trần, rõ mặt, rõ hai tai, không đeo kính, trang phục lịch

Figure 1: Bộ nhớ hội thoại giải tham chiếu đa lượt.

Định vị cơ quan xử lý thủ tục và bản đồ (Map): Sau khi nhận câu trả lời về một thủ tục, người dùng có thể bấm “Địa điểm xử lý gần bạn” để tìm cơ quan, đơn vị tiếp nhận thủ

tục gần vị trí hiện tại. Đây là tính năng do giao diện điều phối, có endpoint dữ liệu ở backend (`rag/places.py`), không phải một công cụ trong vòng lặp ReAct: vị trí đến từ trình duyệt và đầu ra là bản đồ tương tác. Luồng gồm bốn bước (Hình 2): lấy vị trí bằng định vị trình duyệt, hoặc nhập địa chỉ rồi geocode bằng OpenStreetMap Nominatim khi bị từ chối; gọi SerpAPI (engine `google_maps`) theo chiến lược thích nghi theo khoảng cách (thử các mức zoom khác nhau, thêm hậu tố “gần đây” khi truy vấn thừa), chuẩn hoá kết quả và sắp xếp theo khoảng cách haversine; hiển thị danh sách kèm địa chỉ, số điện thoại, giờ làm việc, đánh giá và khoảng cách; vẽ bản đồ Leaflet trên nền OpenStreetMap, tính tuyến đường bằng OSRM kèm quãng đường và thời gian lái xe ước tính, đồng thời cung cấp liên kết mở Google Maps để điều hướng thật. Khi SerpAPI không có dữ liệu tại địa bàn, hệ tự bổ sung kết quả web (Brave) dưới dạng thẻ tham khảo gắn nhãn chưa thẩm định. Các dịch vụ dùng đều miễn phí và chỉ được gọi khi người dùng chủ động bấm.




Figure 2: Luồng định vị cơ quan xử lý thủ tục và bản đồ chỉ đường.




Figure 3: Danh sách địa điểm xử lý gần người dùng: tên, địa chỉ, khoảng cách, đánh giá, sắp xếp gần đến xa.




Figure 4: Bản đồ và chỉ đường tới cơ quan xử lý thủ tục.

Thực nghiệm: đánh giá tăng sinh và trích dẫn: Tiếp nối đánh giá truy hồi ở tuần 3 ($\text{Hit}@5 = 0,922$), tuần này nhóm đo tăng sinh câu trả lời và trích dẫn theo quy trình hai bước (bộ script `rag/eval/*`, kết quả lưu tại `data/eval/`). Trước hết, chạy pipeline ReAct đầy đủ trên một tập con gồm 56 câu in-scope (bảy nhóm $\times 8$) và 8 câu ngoài phạm vi, lưu lại bộ (câu hỏi, câu trả lời, ngữ cảnh, trích dẫn) làm cache để không phải sinh lại. Sau đó chấm bằng gpt-4o làm giám khảo theo hướng reference-free (đối chiếu với chính bằng chứng và câu hỏi, không cần đáp án mẫu) trên các nhóm độ đo: RAG Triad (faithfulness, answer relevance, context precision) theo họ TruLens; trích dẫn theo ALCE (citation recall, precision, F1 dựa trên entailment giữa câu và nguồn dẫn); độ hoàn chỉnh dựa trên checklist gold trích từ corpus; và abstention theo tinh thần SQuAD 2.0 (đo khả năng từ chối câu ngoài phạm vi ở tầng câu trả lời).

Thực nghiệm: ablation bộ nhớ: Để tách riêng đóng góp của bộ nhớ, nhóm mô phỏng của sổ lịch sử ngắn (chỉ giữ 2 lượt gần nhất) và đo độ chính xác giải tham chiếu — câu hỏi tiếp nối sau khi viết lại có chứa đúng thực thể của thủ tục đang nói tới hay không — khi bật/tắt từng lớp. Phép thử B1 kiểm Lớp A (Summary-Buffer) với tham chiếu nằm ở lượt cũ đã trôi khỏi cửa sổ; phép thử B2 kiểm Lớp B (Episodic) với bối cảnh nằm ở hội thoại trước trong khi lịch sử hiện tại rỗng. Kết quả tổng hợp ở Bảng 1.

Cụm	Chỉ số	Giá trị
Sinh (n=56)	Faithfulness / Answer Relevance	0,897 / 0,750
	Context Precision	0,227
Trích dẫn	Citation F1 (Recall / Precision)	0,733 (0,742 / 0,725)
Hoàn chỉnh	Context Recall / Answer Completeness	0,556 / 0,529
Abstention	OOS từ chối / In-scope trả lời	1,000 / 0,964
Bộ nhớ B1 (Lớp A)	Giải tham chiếu: không / có	0% / 100% (n=4)
Bộ nhớ B2 (Lớp B)	Giải tham chiếu: không / có	0% / 100% (n=3)

Table 1: Đánh giá tăng sinh, trích dẫn và ablation bộ nhớ (chi tiết trong báo cáo chính).

Faithfulness 0,90 cho thấy câu trả lời bám nguồn tốt, rủi ro ảo giác thấp; citation F1 0,73 cho thấy trích dẫn đáng tin ở mức khá. Hệ từ chối đúng 100% câu ngoài phạm vi mà gần như không từ chối nhầm (in-scope answer 0,964). Context precision thấp (0,227) là chủ đích thiết kế do cơ chế kéo đủ mọi mục của thủ tục, không phải lỗi truy hồi. Với bộ nhớ, cả B1 và B2 đều cải thiện từ 0% lên 100%: khi tham chiếu vượt cửa sổ lịch sử, baseline viết lại sai hoàn toàn còn bật bộ nhớ thì khôi phục đúng thực thể; cỡ mẫu nhỏ (n=4 và n=3) nên đây là minh chứng có kiểm soát.

Hoàn thiện vận hành và báo cáo: Nhóm chuẩn hoá các kịch bản khởi chạy (`run-backend`, `run-frontend`) bật sẵn chế độ UTF-8 để tránh lỗi mã hoá tiếng Việt trên console Windows, cùng cơ chế chia sẻ index dựng sẵn qua HuggingFace để tái lập nhanh trên máy mới. Tầng LLM và embedding được cấu hình qua tệp `.env` và trang Settings (hiện dùng Azure OpenAI `gpt-4o` và `text-embedding-3-large`; có thể trở tới endpoint tương thích OpenAI), không phải sửa mã nguồn. Về tài liệu, nhóm hoàn thiện báo cáo chính và bốn báo cáo tuần, thống nhất bốn sơ đồ kiến trúc/pipeline và bảng số liệu giữa các tài liệu.

3 Kết quả và sản phẩm bàn giao

Thành phần	Mô tả
<code>rag/memory.py</code>	Bộ nhớ hội thoại 2 lớp: Summary-Buffer và Episodic (Chroma); ablation qua biến môi trường.
<code>rag/places.py</code> , <code>app/api/routers/places.py</code>	Endpoint định vị cơ quan: SerpAPI Maps thích nghi, haversine, dự phòng web.
<code>frontend/</code> (PlacesDialog, MapView)	Giao diện danh sách địa điểm + bản đồ Leaflet + tuyến đường OSRM.
<code>rag/eval/*</code> , <code>data/eval/*</code>	Bộ script và kết quả ba thí nghiệm đánh giá định lượng.
Bộ báo cáo PDF	Báo cáo chính, bốn báo cáo tuần và bốn sơ đồ kiến trúc/pipeline.

4 Khó khăn và hướng xử lý

- Bộ nhớ episodic dùng Chroma cần đường dẫn ASCII để tránh lỗi ghi tệp nhị phân của hnsplib trên Windows; khi chưa có xác thực, `user_id` tạm cố định là `default`.
- Định vị trình duyệt yêu cầu `localhost` hoặc HTTPS, và trên máy không có Wi-Fi thường không lấy được toạ độ chính xác: hệ có sẵn lối nhập địa chỉ tay (geocode bằng Nominatim) làm phương án chắc chắn.
- Hạn mức và độ ổn định dịch vụ ngoài: SerpAPI gói miễn phí chỉ khoảng 100 lượt mỗi tháng nên tính năng chỉ gọi khi người dùng bấm; OSRM và Nominatim cộng đồng không có SLA, phù hợp demo chứ chưa phải production.
- Quy mô đánh giá còn vừa (đặc biệt ablation bộ nhớ với cỡ mẫu nhỏ) và phần lớn dùng LLM làm giám khảo: nhóm nêu rõ giới hạn và xem human evaluation quy mô lớn là hướng tiếp theo.

5 Checklist tuần 4

- ☒ Bộ nhớ hội thoại 2 lớp (Summary-Buffer + Episodic Chroma), ablation qua biến môi trường.
- ☒ Tính năng định vị cơ quan xử lý + bản đồ Leaflet + chỉ đường OSRM + dự phòng web.
- ☒ Thực nghiệm đánh giá tăng sinh, trích dẫn và ablation bộ nhớ (tiếp nối đánh giá truy hồi ở tuần 3).
- ☒ Hoàn thiện báo cáo chính, bốn báo cáo tuần và bốn sơ đồ kiến trúc/pipeline.

6 Kết luận dự án

Sau bốn tuần, đồ án đi trọn một vòng từ khâu dữ liệu (5.208 thủ tục, kho truy hồi ba lớp), qua đường cơ sở một lượt có trích dẫn, tới kiến trúc Agentic RAG (tác tử ReAct hai giai đoạn có minh bạch hoá suy luận và trích dẫn kèm tô sáng), và cuối cùng là bộ nhớ hội thoại đa lượt, tính năng định vị cơ quan xử lý kèm bản đồ chỉ đường, cùng đánh giá định lượng toàn hệ thống. Kết quả là một trợ lý hỏi đáp thủ tục hành chính công có căn cứ, minh bạch, hỏi đáp đa lượt và đã được kiểm chứng định lượng.